

MACHINE LEARNING

COMO AS MÁQUINAS APRENDEM



Caroline Perez Gonçalves
2026

MACHINE LEARNING

Caroline Perez Gonçalves

SUMÁRIO

APRESENTAÇÃO.....	1
INTRODUÇÃO	2
O QUE É MACHINE LEARNING?	3
MACHINE LEARNING DENTRO DA INTELIGÊNCIA ARTIFICIAL.....	4
DIFERENÇA ENTRE IA E MACHINE LEARNING	4
COMO MÁQUINAS CONSEGUEM APRENDER COM DADOS?	5
PREVISÃO OU DECISÃO	5
EXEMPLOS DE MACHINE LEARNING NO DIA A DIA	6
ONDE O MACHINE LEARNING É UTILIZADO?	8
COMO FUNCIONA O APRENDIZADO DE MÁQUINA	10
TIPOS DE APRENDIZADO DE MÁQUINA	14
PRINCIPAIS ALGORITMOS DE MACHINE LEARNING	17
AVALIAÇÃO DE MODELOS DE MACHINE LEARNING.....	21
PREPARANDO OS DADOS.....	24
AGRADECIMENTO.....	28
CONTATO.....	29

APRESENTAÇÃO

Aos que não me conhecem, meu nome é Caroline. Sou formada em Análise e Desenvolvimento de Sistemas, pós-graduada em Inteligência Artificial e Machine Learning e possuo MBA em Gerenciamento de Projetos.

Além da minha experiência profissional com tecnologia, projetos e equipes multidisciplinares, também atuo como instrutora. Sempre acreditei que o conhecimento deve ser compartilhado de forma simples, leve e acessível, e foi com esse propósito que esta apostila foi desenvolvida.

O intuito deste material é mostrar que a Inteligência Artificial está presente em muito mais situações do que imaginamos e que entender essa tecnologia não precisa ser algo complicado. Muito mais do que aprender ferramentas, o mais importante é compreender os conceitos, entender como a IA funciona, onde ela pode ser aplicada e como ela está transformando o mundo ao nosso redor.

Ao final desta apostila, espero que você tenha construído uma base sólida sobre os fundamentos da Inteligência Artificial e se sinta mais confiante para acompanhar as próximas trilhas de estudo e explorar esse universo com mais segurança.

Vamos aos estudos! Mas, antes, sente-se, relaxe e sinta-se em casa. Quero que este material seja como uma boa conversa entre amigos, tornando o aprendizado mais leve, agradável e, principalmente, significativo.

Boa sorte e muito sucesso!

INTRODUÇÃO

Afinal, por que aprender sobre Inteligência Artificial?

A resposta para essa e outras perguntas tem um segredo. Muita gente acredita que Inteligência Artificial é um assunto distante, complicado ou exclusivo para programadores. Mas a verdade é justamente o contrário.

Como assim, Carol?

A Inteligência Artificial já faz parte da nossa rotina. Ela está presente quando recebemos uma recomendação de filme, usamos um aplicativo de navegação, conversamos com um assistente virtual, fazemos uma compra online ou até quando desbloqueamos o celular com o reconhecimento facial.

Quando você entende isso, percebe que estudar IA não significa apenas aprender uma nova tecnologia. Significa compreender uma transformação que já está acontecendo e que impacta praticamente todas as áreas do conhecimento e do mercado de trabalho.

E tem mais: aprender Inteligência Artificial não é aprender apenas a utilizar ferramentas. As ferramentas mudam o tempo todo. O que realmente faz diferença é entender os conceitos, saber como a IA funciona, conhecer suas possibilidades e também suas limitações. Com essa base, aprender novas tecnologias se torna muito mais fácil.

Claro, existem assuntos mais avançados que exigem bastante estudo e prática. Mas, como em qualquer aprendizado, tudo começa pelos fundamentos. E é exatamente isso que vamos construir ao longo desta apostila.

Para que essa introdução não fique muito extensa, vamos explorar cada tema no momento certo. E, como todo bom aprendizado, vamos começar pelo começo.

Vamos lá.

O QUE É MACHINE LEARNING?

Na apostila anterior, aprendemos que a Inteligência Artificial é uma grande área da tecnologia que busca criar sistemas capazes de realizar tarefas que normalmente exigiriam algum tipo de inteligência humana.

Dentro desse universo existe uma área muito importante chamada **Machine Learning**, ou **Aprendizado de Máquina**.

Mas afinal, o que é Machine Learning?

De forma simples, podemos dizer que Machine Learning é uma área da Inteligência Artificial que permite que computadores aprendam através de dados, sem precisar receber todas as regras programadas manualmente.

Mas como assim uma máquina aprende? Vamos imaginar uma situação do nosso dia a dia.

Imagine que você queira criar um sistema capaz de identificar se uma mensagem recebida por e-mail é um spam ou não.

Uma forma tradicional de programar esse sistema seria criar várias regras:

“Se a mensagem tiver determinada palavra, pode ser spam.”

“Se vier de determinado endereço, pode ser spam.”

“Se apresentar determinado comportamento, pode ser spam.”

O problema é que existem milhares de possibilidades diferentes. Pessoas mal-intencionadas podem mudar palavras, criar novos formatos de mensagens e encontrar maneiras diferentes de tentar enganar o sistema.

Seria como tentar criar um manual infinito dizendo para uma pessoa:

“Se acontecer isso, faça aquilo. Se acontecer outra coisa, faça isso.”

Uma hora esse manual ficaria tão grande que ninguém teria paciência nem para abrir a primeira página. É nesse ponto que entra o Machine Learning.

Em vez de ensinar todas as regras possíveis para a máquina, nós mostramos muitos exemplos para que ela consiga encontrar padrões.

O sistema recebe dados de mensagens antigas, analisa características em comum e aprende a identificar quais comportamentos costumam estar relacionados a mensagens de spam.

Depois desse aprendizado, quando uma nova mensagem chega, o modelo consegue analisar as informações e fazer uma previsão:

“Essa mensagem tem características parecidas com aquelas que já foram identificadas como spam. Existe uma grande chance de ser uma mensagem indesejada.”

Ou seja, no Machine Learning, nós não ensinamos todas as respostas. Nós ensinamos a máquina a encontrar padrões. E é justamente essa capacidade de identificar padrões que torna essa tecnologia tão poderosa.

MACHINE LEARNING DENTRO DA INTELIGÊNCIA ARTIFICIAL

Quando falamos sobre Inteligência Artificial, muitas pessoas imaginam que tudo é a mesma coisa. Porém, existe uma diferença entre esses conceitos.

A Inteligência Artificial é uma grande área de estudo que busca criar sistemas capazes de executar tarefas que normalmente dependeriam da inteligência humana. Dentro dela existem diferentes técnicas e áreas de pesquisa. O Machine Learning é uma dessas áreas. Podemos imaginar a relação da seguinte forma:

Inteligência Artificial > Machine Learning > Deep Learning

A Inteligência Artificial é o conceito mais amplo. Ela representa o objetivo de criar máquinas capazes de realizar tarefas inteligentes.

O Machine Learning é uma das formas utilizadas para alcançar esse objetivo, permitindo que sistemas aprendam através de dados.

Já o Deep Learning é uma evolução do Machine Learning, utilizando estruturas mais complexas chamadas de redes neurais artificiais.

Calma, isso não significa que criaram um cérebro dentro do computador. Ainda não chegamos nesse ponto (e talvez seja melhor deixar o café longe dos robôs por enquanto. Não posso perder essa piada, mesmo que seja repetitiva).

O que acontece é que essas redes foram inspiradas em algumas características do funcionamento do cérebro humano para conseguir analisar informações de maneira mais avançada.

DIFERENÇA ENTRE IA E MACHINE LEARNING

Apesar de muitas pessoas utilizarem os termos Inteligência Artificial e Machine Learning como se fossem a mesma coisa, eles possuem diferenças.

A Inteligência Artificial representa o objetivo, como criar sistemas capazes de realizar atividades consideradas inteligentes.

Já o Machine Learning representa uma das tecnologias utilizadas para tornar isso possível. Permitir que sistemas aprendam através de dados. Vamos imaginar um exemplo: um aplicativo de música consegue recomendar músicas que provavelmente você vai gostar.

Essa recomendação faz parte de uma aplicação de Inteligência Artificial. Mas como o aplicativo consegue saber quais músicas sugerir?

Ele pode utilizar Machine Learning para analisar informações como: as músicas que você costuma ouvir; os artistas que você mais gosta; os horários em que você utiliza o aplicativo; os estilos musicais escolhidos; o comportamento de usuários com gostos parecidos.

A partir dessas informações, o sistema identifica padrões. Por exemplo:

“Pessoas que escutam esses artistas geralmente também gostam desses outros.”

Então ele faz uma sugestão. É como quando alguém próximo conhece muito seu gosto musical e fala: você gosta dessa banda? Então provavelmente vai gostar dessa outra também. Escuta aí.

A diferença é que a máquina consegue fazer essa análise com milhões de usuários e uma quantidade gigantesca de informações.

1. A Inteligência Artificial é o conceito geral.
2. O Machine Learning é uma das tecnologias que torna esse conceito possível.

COMO MÁQUINAS CONSEGUEM APRENDER COM DADOS?

Quando ouvimos a palavra “aprender”, automaticamente pensamos em seres humanos. Afinal, nós aprendemos através de experiências, estudos, conversas e observações. Mas o aprendizado de uma máquina acontece de uma forma diferente.

Um modelo de Machine Learning não aprende como uma pessoa aprende. Ele não entende o significado das coisas da mesma maneira que nós.

O que ele faz é analisar grandes quantidades de dados, encontrar padrões e utilizar essas informações para realizar previsões. Vamos imaginar novamente uma situação prática. Vem comigo...

Uma empresa quer criar um sistema capaz de prever o preço de imóveis. Para isso, ela precisa fornecer informações sobre diversos imóveis já vendidos. Essas informações podem incluir: localização, tamanho do imóvel, quantidade de quartos, características da região e histórico de vendas.

Com esses dados, o modelo começa a analisar relações.

Ele pode perceber, por exemplo, que imóveis maiores normalmente possuem valores mais altos. Pode identificar que determinadas regiões possuem preços acima da média. Pode entender que algumas características influenciam mais no valor final.

A máquina não está “pensando” que esse apartamento é bonito, então vale mais. Ela está encontrando padrões matemáticos nos dados que recebeu. É como se ela estivesse dizendo:

“Com base em milhares de exemplos anteriores, imóveis com essas características costumam ter valores próximos a esse.”

E é assim que o aprendizado acontece.

PREVISÃO OU DECISÃO

Depois que o modelo passou pelo treinamento, chegou a hora de colocá-lo para funcionar.

Agora ele recebe novos dados e utiliza tudo aquilo que aprendeu para gerar uma resposta. Voltando ao exemplo dos imóveis:

Depois de analisar milhares de informações de imóveis vendidos anteriormente, o modelo aprendeu quais características costumam influenciar no preço.

Então, quando apresentamos um novo imóvel, informando dados como localização, tamanho, quantidade de quartos e outras características, ele analisa essas informações e faz uma estimativa. Por exemplo:

“Com base nos padrões encontrados nos dados anteriores, esse imóvel provavelmente possui um valor próximo de determinado preço.”

Mas atenção: estamos falando de uma previsão, não de uma certeza.

A Inteligência Artificial não está olhando para o futuro como uma pessoa que tem uma bola de cristal (apesar de algumas propagandas de tecnologia fazerem parecer isso).

Ela está utilizando informações do passado para encontrar padrões e gerar uma possibilidade baseada nesses dados. Quanto melhores forem os dados utilizados no treinamento, maior a chance de o modelo apresentar resultados mais confiáveis.

EXEMPLOS DE MACHINE LEARNING NO DIA A DIA

Falamos brevemente sobre isso na apostila anterior, mas vale aprofundar esse assunto.

Talvez você ainda não tenha percebido, mas o Machine Learning já faz parte da nossa rotina. Muitas tecnologias que utilizamos diariamente possuem modelos capazes de analisar nosso comportamento, encontrar padrões e realizar previsões. Vamos conhecer alguns exemplos.

Recomendações de filmes e músicas

Sabe quando você termina uma série e, poucos segundos depois, aparece aquela sugestão: “Você também pode gostar disso”?

Não é mágica. Também não é alguém sentado dentro da plataforma escolhendo filmes para você assistir. (Embora às vezes pareça que alguém conhece nossos gostos melhor do que nós mesmos).

Plataformas de streaming utilizam Machine Learning para analisar informações como:

Os conteúdos que você assistiu;

Quanto tempo permaneceu assistindo determinado filme ou série;

Quais músicas você ouviu;

Suas avaliações;

Preferências de usuários com comportamentos semelhantes.

A partir desses dados, o sistema encontra padrões e sugere conteúdos que possuem maior chance de combinar com seus interesses. Por exemplo:

Se milhares de pessoas que assistiram determinados filmes também gostaram de outro conteúdo, a plataforma pode entender que existe uma relação entre esses interesses e fazer uma recomendação.

Reconhecimento facial

Quando você desbloqueia seu celular utilizando o rosto, existe uma Inteligência Artificial trabalhando por trás dessa ação.

O sistema analisa características da imagem e identifica padrões únicos daquela pessoa. Ele observa informações como:

Formato do rosto;

Distância entre os elementos da face;

Características específicas da imagem.

A máquina não olha para você e pensa: “Ah, é a Caroline, dona desse celular.”

Ela não possui essa compreensão humana. O que acontece é uma comparação de padrões matemáticos entre a imagem capturada e as informações aprendidas anteriormente.

Assistentes virtuais

Assistentes inteligentes também utilizam Machine Learning para interpretar comandos e entender o que uma pessoa deseja. Quando você pergunta:

“Qual a previsão do tempo hoje?” ou “Toque uma música.”

Existe um sistema analisando as palavras utilizadas, o contexto da solicitação e padrões de linguagem para identificar a intenção daquela mensagem.

A máquina não entende uma conversa exatamente como um ser humano entende, mas consegue analisar informações e encontrar relações que ajudam a oferecer uma resposta adequada.

Detecção de fraudes

Os bancos são grandes usuários de Machine Learning, principalmente para aumentar a segurança das operações financeiras.

Imagine que uma pessoa normalmente realiza compras em determinada cidade, com valores próximos e em horários específicos. De repente, aparece uma compra muito diferente:

Um valor muito alto;

Em outro país;

Em um horário incomum.

O sistema pode identificar que aquele comportamento foge do padrão. Ele analisa informações como local da compra, horário, valor e histórico de movimentações.

A partir disso, pode gerar um alerta ou solicitar uma confirmação. É aquele famoso momento em que o banco pergunta: “Foi você que realizou essa compra?”

Às vezes parece até que o banco conhece nossa vida melhor do que alguns parentes. Inclusive, isso é utilizado até em golpes! Mas, vamos nos aprofundar sobre isso em outro momento.

ONDE O MACHINE LEARNING É UTILIZADO?

O Machine Learning não está presente apenas em aplicativos de entretenimento ou celulares. Ele é utilizado em diversas áreas profissionais e possui aplicações que podem gerar impactos importantes.

Saúde

Na área da saúde, o Machine Learning pode auxiliar profissionais na análise de informações médicas. Ele pode ajudar em atividades como:

Análise de exames;

Identificação de padrões médicos;

Previsão de possíveis riscos;

Apoio ao diagnóstico.

Por exemplo: um modelo pode analisar milhares de exames anteriores e identificar

características que aparecem com frequência em determinados casos.

Mas é importante lembrar: a tecnologia funciona como **apoio** aos profissionais. Ela não substitui médicos ou especialistas. **A-P-O-I-O!**

A decisão final continua envolvendo conhecimento, experiência e avaliação humana.

Finanças

No setor financeiro, o Machine Learning possui diversas aplicações. Ele pode ser utilizado para:

Detectar fraudes;

Analisar riscos de crédito;

Prever comportamentos;

Automatizar processos.

Bancos e instituições financeiras utilizam esses modelos porque analisam uma quantidade enorme de informações diariamente. Seria praticamente impossível uma pessoa verificar manualmente cada movimentação realizada por milhões de clientes.

Marketing e vendas

Empresas utilizam Machine Learning para entender melhor seus consumidores. Ele pode ajudar a:

Identificar padrões de comportamento;

Criar recomendações personalizadas;

Prever tendências;

Melhorar campanhas de marketing.

Por exemplo: uma loja pode analisar quais produtos costumam ser comprados juntos e utilizar essa informação para criar melhores ofertas. É aquela situação: “Você comprou um celular? Talvez também precise de uma capinha e uma película. Vejo que você vai derrubar o celular muito em breve.”

A tecnologia percebe essas relações através dos dados.

Indústria

Na indústria, o Machine Learning ajuda a tornar processos mais eficientes. Ele pode

ser utilizado em:

Manutenção preventiva;

Controle de qualidade;

Automação de processos;

Otimização da produção.

Um exemplo é uma máquina industrial que apresenta pequenos sinais antes de uma falha. O modelo pode analisar esses padrões e indicar que uma manutenção deve ser realizada antes que aconteça um problema maior.

É como perceber aquele barulho estranho no carro antes de ele parar completamente na estrada. Melhor resolver antes, certo?

Tecnologia

Na área de tecnologia, o Machine Learning aparece em diversas soluções. Ele está presente em:

Sistemas inteligentes;

Aplicações com Inteligência Artificial;

Segurança digital;

Automação de tarefas.

Muitas ferramentas que utilizamos atualmente dependem de modelos capazes de analisar dados e melhorar seus resultados ao longo do tempo.

COMO FUNCIONA O APRENDIZADO DE MÁQUINA

Até aqui, já entendemos que o Machine Learning aprende através de dados. Mas ficou uma pergunta importante: **como esse aprendizado realmente acontece?**

Quando falamos que uma máquina "aprende", pode parecer que ela pensa sozinha, cria ideias ou entende as coisas como nós. Mas não é bem assim. Isso precisa ficar bem claro para você!

Na prática, o processo é muito mais organizado.

A máquina recebe informações, analisa milhares de exemplos, procura características em comum e, depois disso, consegue fazer previsões sobre situações novas. Vamos

imaginar um exemplo.

Suponha que queremos ensinar um computador a identificar se um e-mail é spam ou não. Em vez de criar centenas ou milhares de regras dizendo:

"Se tiver essa palavra, é spam."

"Se vier desse endereço, é spam."

"Se tiver muitos links, é spam."

...fazemos algo muito mais inteligente. Mostramos para a máquina milhares de mensagens que já sabemos quais são spam e quais são mensagens normais. A partir daí, ela começa a observar os exemplos.

Ela percebe que muitas mensagens de spam possuem ofertas exageradas, links suspeitos, palavras como "grátis", "ganhe dinheiro", "clique agora" ou até determinados comportamentos de envio.

Depois de analisar muitos exemplos, ela consegue olhar para uma mensagem que nunca viu antes e pensar (entre muitas aspas):

"Essa mensagem é muito parecida com outras que já aprendi. Provavelmente é um spam."

Perceba que ela não entendeu o significado da mensagem como um ser humano entenderia. Ela apenas encontrou padrões. E esse é o princípio básico do Machine Learning.

Dados: o combustível do aprendizado

Se existe uma palavra que você vai encontrar muitas vezes quando estudar Machine Learning, essa palavra é **dados**.

Lá na apostila anterior eu comparei os dados ao combustível de um carro. E continuo gostando desse exemplo. Você pode comprar o carro mais moderno do mundo. Se não colocar combustível, ele simplesmente não vai sair do lugar. Sim, estou me referindo apenas aos veículos à combustão!

Com o Machine Learning acontece exatamente a mesma coisa. Os dados são o combustível que permite que a máquina aprenda.

Sem dados, não existe aprendizado.

Imagine tentar aprender inglês sem nunca ouvir uma palavra em inglês (eu já não consigo aprender nem ouvindo, quem dirá sem ouvir). Ou aprender a cozinhar sem nunca assistir a uma receita, ler um livro ou entrar na cozinha. Seria praticamente impossível.

Com as máquinas acontece algo parecido. Quanto mais exemplos de qualidade ela recebe, maiores são as chances de aprender corretamente.

Esses dados podem ser fotos para reconhecer pessoas, histórico de compras para recomendar produtos, informações financeiras para detectar fraudes, textos para compreender a linguagem humana ou até exames médicos para auxiliar profissionais da saúde.

Cada conjunto de dados ensina uma habilidade diferente para o modelo.

Características (as famosas “Features”)

Dentro desses dados existem informações que ajudam a máquina a tomar decisões. Essas informações recebem o nome de **features**, ou **características**.

Pode parecer um nome complicado, mas a ideia é simples. Imagine que queremos criar um modelo capaz de prever o preço de uma casa. Quais informações você utilizaria?

Provavelmente tamanho do imóvel, localização, quantidade de quartos, número de banheiros e idade da construção. Essas são as características que ajudam o modelo a entender o valor daquele imóvel.

Agora imagine que, em vez disso, resolvemos informar apenas a cor do portão da casa. Será que isso ajuda muito a descobrir quanto ela vale? Provavelmente não.

Por isso, escolher boas características faz toda a diferença. Quanto mais relevantes forem essas informações, maior a chance de o modelo aprender corretamente.

Encontrando padrões

O principal trabalho do Machine Learning é encontrar padrões escondidos nos dados. Nós também fazemos isso o tempo todo. Percebemos que determinada avenida sempre fica congestionada em certo horário. Sabemos que um restaurante costuma ficar cheio aos domingos. Ou descobrimos que aquele amigo sempre fala "é rapidinho" antes de pedir um favor que demora duas horas.

Nosso cérebro identifica padrões naturalmente. O problema é quando existem milhões de informações para analisar. É aí que entra o Machine Learning.

Imagine uma loja virtual com milhões de compras registradas. Seria praticamente impossível alguém analisar todas essas informações manualmente.

O modelo consegue encontrar relações como:

Pessoas que comprem determinado produto costumam comprar outro logo depois.

Alguns produtos vendem muito mais em determinadas épocas do ano.

Certos clientes possuem maior chance de voltar a comprar.

Esses padrões ajudam empresas a entender melhor seus clientes e tomar decisões mais inteligentes.

Treinamento e previsão

De forma geral, o aprendizado acontece em duas etapas.

A primeira é o **treinamento**.

É durante essa fase que o modelo recebe milhares ou até milhões de exemplos (eu já disse isso, né?).

Ele compara informações, procura relações entre os dados e ajusta seu funcionamento para aprender cada vez melhor. É como um estudante se preparando para uma prova. Quanto mais ele pratica e resolve exercícios, maiores são as chances de ter um bom desempenho.

Depois vem a segunda etapa: a **previsão**.

Agora o modelo recebe dados que nunca viu antes. Utilizando tudo o que aprendeu durante o treinamento, ele gera uma resposta.

Imagine um modelo treinado com milhares de imagens de cães (desculpe, minha criatividade só está para isso) e gatos.

Ao receber uma nova fotografia, ele analisa suas características e responde:

"Essa imagem provavelmente representa um cachorro."

Perceba que a palavra importante aqui é **provavelmente**. Ele não tem certeza absoluta. Está fazendo uma previsão baseada nos padrões encontrados durante o treinamento.

Entrada, processamento e saída

Também podemos entender o funcionamento do Machine Learning imaginando um processo dividido em três etapas.

Primeiro temos a **entrada (input)**.

É o momento em que fornecemos as informações para o modelo. Pode ser uma foto, um texto, um áudio, uma planilha ou qualquer outro tipo de dado.

Depois acontece o **processamento**.

É aqui que a "mágica" acontece. Mas calma, não é mágica de verdade. O modelo compara os novos dados com tudo aquilo que aprendeu durante o treinamento e procura padrões semelhantes.

Por último, temos a **saída (output)**.

É o resultado gerado pelo modelo. Essa saída pode ser uma classificação, uma previsão, uma recomendação ou até uma resposta para uma pergunta.

Voltando ao nosso amigo cachorro (sim, ele apareceu de novo), imagine que enviamos uma foto de um animal.

O modelo analisa as características da imagem e responde:

"Provavelmente é um cachorro."

Simples assim. Fim.

TIPOS DE APRENDIZADO DE MÁQUINA

Agora que já entendemos como funciona o aprendizado de máquina, chegou o momento de conhecer as principais formas que uma máquina pode aprender. E não, não existe apenas uma.

Assim como nós aprendemos de maneiras diferentes, os modelos de Machine Learning também.

Tem gente que aprende melhor assistindo uma aula. Outros preferem colocar a mão na massa e descobrir tudo sozinhos. Tem também aquela pessoa que só aprende depois de errar algumas vezes (ou muitas... sem julgamentos).

Com as máquinas acontece algo parecido.

Dependendo do problema que queremos resolver e dos dados que temos disponíveis, utilizamos um tipo diferente de aprendizado. Os três principais são:

- aprendizado supervisionado;
- aprendizado não supervisionado;
- aprendizado por reforço.

Cada um possui características próprias e é indicado para situações diferentes.

Aprendizado supervisionado

O aprendizado supervisionado é o tipo mais utilizado em projetos de Machine

Learning.

Nesse modelo, a máquina aprende utilizando exemplos que já possuem a resposta correta. É como se ela tivesse um professor acompanhando todo o processo.

Imagine uma criança aprendendo a reconhecer frutas. Você mostra uma maçã e diz:

"Isso é uma maçã."

Depois mostra uma banana.

"Isso é uma banana."

Depois mostra uma laranja.

"Isso é uma laranja."

Depois de muitos exemplos, a criança começa a reconhecer novas frutas sem precisar perguntar toda hora. A máquina faz exatamente a mesma coisa. Ela recebe milhares de exemplos já classificados e começa a procurar padrões.

Vamos voltar ao exemplo dos e-mails.

Durante o treinamento, mostramos milhares de mensagens. Algumas são marcadas como spam. Outras são marcadas como mensagens normais.

O modelo observa todas elas e percebe que mensagens de spam costumam ter determinadas características, como ofertas exageradas, links suspeitos, pedidos urgentes para clicar em alguma coisa e por aí vai.

Depois desse treinamento, quando chega um e-mail novo, ele faz uma previsão:

"Provavelmente isso é spam."

Repare em uma palavra importante: provavelmente.

Novamente isso, Carol? Sim. O Machine Learning trabalha com probabilidades.

Ele não "tem certeza". Ele analisa aquilo que aprendeu e toma uma decisão baseada nos padrões encontrados. Por isso, de vez em quando aquele e-mail importante acaba indo parar na caixa de spam. A máquina também erra. Afinal, ninguém é perfeito... nem ela.

O aprendizado supervisionado é muito utilizado para prever preços de imóveis, detectar fraudes bancárias, reconhecer imagens, classificar documentos, identificar doenças e até recomendar filmes e músicas.

Aprendizado não supervisionado

Agora imagine uma situação diferente.

Você entrega milhares de informações para a máquina, mas não diz absolutamente nada sobre elas. Nada de respostas prontas. Nada de "isso está certo" ou "isso está errado". Ela precisa descobrir tudo sozinha.

É exatamente assim que funciona o aprendizado não supervisionado.

O objetivo não é prever uma resposta, mas encontrar padrões escondidos dentro dos dados. Imagine uma loja que possui milhões de clientes. Ela sabe quanto cada pessoa compra, com que frequência compra, quais produtos costuma adquirir e quanto costuma gastar. Mas ninguém sabe exatamente quais perfis de clientes existem.

O modelo começa a analisar todas essas informações e, sozinho, percebe alguns grupos:

- Um grupo compra pouco, mas compra sempre;
- Outro compra apenas quando existem promoções;
- Outro faz poucas compras, mas quando compra, gasta bastante.

Ninguém criou essas categorias. Foi a própria máquina que encontrou esses padrões.

Essas informações ajudam muito as empresas na hora de entender melhor seus clientes e criar estratégias específicas para cada grupo.

Esse tipo de aprendizado é muito utilizado em segmentação de clientes, análise de comportamento, organização automática de informações e descoberta de padrões que muitas vezes passariam despercebidos por uma pessoa.

Aprendizado por reforço

O aprendizado por reforço funciona de uma maneira bem diferente dos anteriores. Aqui, a máquina aprende através de tentativa, erro e recompensa. É quase como aprender um jogo novo.

No começo você não sabe muito bem o que fazer, testa uma estratégia, perde, tenta outra, perde de novo (...) e, depois de várias tentativas, começa a perceber quais decisões funcionam melhor. A máquina passa exatamente pelo mesmo processo.

Ela realiza uma ação > recebe um retorno.

Se a decisão foi boa > recebe uma recompensa.

Se foi ruim > recebe uma penalização.

Então ajusta seu comportamento e tenta novamente. E de novo. E mais uma vez. Até encontrar a melhor estratégia possível. Um bom exemplo é um robô aprendendo a andar. Nas primeiras tentativas, ele pode cair várias vezes (e sim, dá até uma certa dó... mas faz parte. 😊). A cada tentativa ele ajusta seus movimentos, aprende com os erros e melhora seu equilíbrio.

Outro exemplo muito conhecido são as Inteligências Artificiais que aprendem a jogar xadrez ou videogames. Elas jogam milhares (às vezes milhões) de partidas contra elas mesmas até descobrir quais estratégias aumentam suas chances de vitória.

Esse tipo de aprendizado é bastante utilizado em robótica, veículos autônomos, jogos eletrônicos, otimização de processos e controle de máquinas.

Qual deles é o melhor?

Se você respondeu "depende", parabéns! Já está pensando como alguém que trabalha com tecnologia.

Não existe um tipo de aprendizado que seja melhor que o outro. Tudo depende do problema que queremos resolver.

Se temos exemplos com respostas conhecidas, normalmente utilizamos aprendizado supervisionado.

Se queremos descobrir padrões escondidos nos dados, o aprendizado não supervisionado costuma ser a melhor escolha.

Agora, se o sistema precisa aprender tomando decisões e melhorando continuamente através da experiência, o aprendizado por reforço costuma ser o mais indicado.

Cada abordagem foi criada para resolver um tipo diferente de desafio.

PRINCIPAIS ALGORITMOS DE MACHINE LEARNING

Agora que já entendemos como uma máquina aprende e conhecemos os principais tipos de aprendizado, chegou a hora de conhecer quem realmente faz o trabalho pesado: os algoritmos.

Se eu pudesse fazer uma comparação simples, diria que o Machine Learning é como uma caixa de ferramentas. Dentro dela existem várias ferramentas diferentes. Um martelo serve para uma coisa, uma chave de fenda para outra e um alicate para outra completamente diferente. Às vezes EU coloco um prego na parede batendo com um alicate? Sim. Mas, não vem ao caso aqui na execução de Machine Learning!

Cada algoritmo foi criado para resolver determinados tipos de problemas. Alguns são

melhores para fazer previsões, outros para classificar informações e outros para encontrar padrões escondidos nos dados.

Por isso, não existe um algoritmo que seja o melhor de todos. Existe aquele que faz mais sentido para cada situação. Vamos conhecer alguns dos principais.

Regressão Linear

A Regressão Linear é um dos algoritmos mais conhecidos e também um dos mais simples de entender. Seu principal objetivo é prever valores numéricos.

Imagine que uma imobiliária queira descobrir quanto vale uma casa antes mesmo de colocá-la à venda.

Para isso, o algoritmo pode analisar informações como o tamanho do imóvel, a quantidade de quartos, a localização, a idade da construção e várias outras características.

Depois de analisar milhares de imóveis que já foram vendidos, ele começa a perceber alguns padrões. Casas maiores costumam valer mais. Algumas regiões possuem preços mais elevados. Um imóvel recém-construído pode ter um valor diferente de outro mais antigo.

Quando aparece uma casa nova, o algoritmo utiliza tudo o que aprendeu para estimar um preço.

Repare na palavra "estimar". Ele não consulta uma tabela escondida nem possui uma bola de cristal (se tivesse, muita gente queria esse algoritmo para apostar na Mega-Sena).

Ele apenas faz uma previsão baseada nos dados que recebeu durante o treinamento.

Além do mercado imobiliário, a Regressão Linear também pode ser utilizada para prever vendas, consumo de energia, faturamento e diversos outros valores numéricos.

Curiosidade: uso sempre os mesmos exemplos na intenção de sempre criar um vínculo na cabeça enquanto aprendemos. Pode parecer repetitivo (e é), pode parecer chato (e é também), mas quando criamos conexões com cenários que já sabemos, conseguimos lembrar e aprender melhor. Então, sempre que eu tiver oportunidade, vou falar sobre casas e... sobre cachorros.

Regressão Logística

Apesar do nome parecer muito parecido com a Regressão Linear, a função dela é completamente diferente.

Enquanto a Regressão Linear prevê números, a Regressão Logística normalmente responde perguntas. Perguntas como:

"Esse e-mail é spam ou não?"

"Esse cliente vai cancelar a assinatura?"

"Essa compra pode ser uma fraude?"

"Esse paciente possui maior risco de determinada doença?"

Percebeu que, na maioria das vezes, a resposta é "sim" ou "não"? É exatamente esse tipo de problema que esse algoritmo ajuda a resolver. Ele analisa diversas informações e calcula qual é a probabilidade de determinado evento acontecer.

Imagine um banco analisando um pedido de empréstimo.

O algoritmo pode observar a renda da pessoa, seu histórico financeiro, pagamentos anteriores e outros fatores importantes. Depois disso, calcula a probabilidade daquele cliente conseguir pagar o empréstimo.

A decisão final nem sempre é tomada automaticamente, mas essa previsão ajuda muito quem precisa analisar centenas ou milhares de solicitações todos os dias.

Árvores de Decisão

A Árvore de Decisão é um dos algoritmos mais fáceis de visualizar. Ela funciona como uma sequência de perguntas.

Vamos imaginar que um banco esteja analisando um pedido de financiamento. A primeira pergunta pode ser:

A pessoa possui renda fixa?

Se a resposta for sim, o sistema faz outra pergunta.

Ela possui um bom histórico de pagamentos?

Se a resposta continuar sendo positiva, surgem novas perguntas até chegar a uma decisão.

Se alguma resposta indicar um risco elevado, o caminho muda completamente.

É justamente por isso que esse algoritmo recebe o nome de Árvore de Decisão.

Cada resposta leva para um novo "galho", até chegar ao resultado final.

Uma das maiores vantagens desse algoritmo é que conseguimos entender facilmente como ele chegou à conclusão. Diferente de alguns modelos mais complexos, aqui o caminho costuma ser bastante transparente.

Random Forest

Agora imagine que, em vez de perguntar a opinião de apenas uma pessoa, você perguntasse para cem pessoas antes de tomar uma decisão importante. Provavelmente a resposta seria mais confiável, não é? Essa é exatamente a ideia do Random Forest.

Em vez de utilizar apenas uma Árvore de Decisão, ele cria várias árvores diferentes. Cada uma analisa os dados de uma maneira um pouco diferente. No final, todas "votam" na resposta que consideram mais correta.

A decisão mais escolhida costuma ser utilizada como resultado.

Isso reduz a chance de erros e normalmente produz previsões mais confiáveis.

Por esse motivo, o Random Forest é muito utilizado em análise financeira, detecção de fraudes, classificação de clientes, análise de riscos e diversas outras aplicações empresariais.

K-Means

Até agora vimos algoritmos que fazem previsões ou classificações. O K-Means trabalha de outra forma.

Ele procura grupos naturalmente existentes dentro dos dados. Imagine uma loja com milhares de clientes. Ela sabe quanto cada cliente compra, quanto costuma gastar, quais produtos prefere e com que frequência realiza novas compras.

Mas ninguém organizou essas pessoas em grupos. O K-Means faz esse trabalho automaticamente.

Depois de analisar todas as informações, ele pode descobrir, por exemplo, um grupo de clientes que compra pouco, mas compra sempre. Outro grupo pode gastar muito dinheiro em poucas compras. Já outro aparece somente durante grandes promoções.

Ninguém ensinou esses grupos para a máquina.

Ela encontrou essas semelhanças sozinha.

Essas informações ajudam bastante empresas que desejam criar campanhas específicas para cada perfil de cliente. Falamos sobre isso um pouco mais acima, lembra? Pois bem. Agora você já sabe: K-Means.

Redes Neurais

As Redes Neurais são uma das tecnologias mais conhecidas dentro do Machine Learning.

Elas foram inspiradas no funcionamento do cérebro humano. Calma... isso não significa que colocaram um cérebro dentro do computador (já fiz essa piada umas duas vezes, né?).

A inspiração está apenas na forma como várias pequenas unidades trabalham juntas para processar informações. Enquanto algoritmos mais simples conseguem encontrar padrões relativamente fáceis, as Redes Neurais conseguem aprender relações muito mais complexas.

É justamente por isso que elas são utilizadas em reconhecimento facial, reconhecimento de voz, tradução automática, geração de imagens, criação de textos e diversas aplicações de Inteligência Artificial Generativa.

Quando você desbloqueia o celular usando o rosto, por exemplo, existe uma boa chance de uma Rede Neural estar trabalhando nos bastidores para identificar se quem está segurando o aparelho realmente é você.

As Redes Neurais também são a base do Deep Learning, assunto que veremos com muito mais detalhes em outro momento.

AVALIAÇÃO DE MODELOS DE MACHINE LEARNING

Até agora, vimos como um modelo de Machine Learning aprende utilizando dados. Mas agora surge uma pergunta muito importante: **"Como sabemos se ele realmente aprendeu?"**

Porque existe uma diferença enorme entre **aprender** e **achar que aprendeu**. Eu já achei muitas vezes que tinha aprendido e... Bom, deixa quieto.

É igual quando a gente estuda para uma prova. Às vezes fazemos dez exercícios iguais e pensamos: "Nossa, agora eu domino esse assunto!". Aí chega o dia da prova... e aparece uma questão diferente. Pronto. O cérebro entra em modo avião.

Com as máquinas acontece exatamente a mesma coisa.

Depois que um modelo termina o treinamento, precisamos verificar se ele consegue tomar boas decisões com dados que nunca viu antes. É justamente para isso que existe a avaliação de modelos. Ela serve para responder perguntas como:

- O modelo está acertando?
- Está errando muito?
- Está aprendendo de verdade ou apenas decorou os exemplos?

Parece uma prova, e na prática é quase isso mesmo.

Dados de treinamento e dados de teste

Imagine que você está estudando para tirar carteira de motorista. Durante as aulas, você pratica várias situações com o instrutor. Mas, no dia do exame, quem vai avaliar você é outra pessoa. No Machine Learning acontece algo parecido.

Primeiro temos os **dados de treinamento**.

São os exemplos utilizados para ensinar o modelo.

Se quisermos criar uma IA capaz de reconhecer cachorros e gatos (sim, o cachorro voltou. Eu avisei que ele apareceria de novo...), mostramos milhares de imagens para ela aprender as diferenças entre os dois animais.

Depois entram os **dados de teste**.

Esses dados nunca foram apresentados durante o treinamento. Eles servem justamente para verificar se o modelo realmente aprendeu ou se apenas decorou os exemplos anteriores.

Se ele conseguir responder corretamente utilizando informações completamente novas, é um ótimo sinal.

Caso contrário... talvez ele precise estudar mais um pouco.

Acurácia

Uma das formas mais conhecidas de avaliar um modelo é através da **acurácia**. Ela mostra a porcentagem de respostas corretas.

Imagine que um modelo analisou 100 imagens. Ele acertou 90 delas. Sua acurácia foi de 90%. Parece excelente, não é?

Na maioria das situações, sim.

Mas existe um detalhe importante. Imagine um sistema que precisa identificar uma doença muito rara. Suponha que apenas 1 pessoa em cada 100 esteja realmente doente. Agora imagine uma IA muito "esperta" que responde "não está doente" para absolutamente todo mundo.

Ela acertaria 99 pessoas.

Ou seja...

A acurácia seria de 99%.

Só existe um pequeno problema. Ela não encontrou justamente a única pessoa que precisava ser identificada. Por isso, olhar apenas para a acurácia nem sempre é

suficiente.

Precisão (Precision)

A precisão responde outra pergunta:

"Quando o modelo disse que encontrou um caso positivo, quantas vezes ele realmente acertou?"

Vamos imaginar um banco tentando identificar fraudes. O sistema marcou 100 compras como suspeitas. Depois da análise, descobriram que apenas 80 realmente eram fraudes.

Isso significa que a precisão do modelo foi alta, mas ainda existiram alguns falsos alarmes. É como aquele amigo que desconfia de tudo. Uma pessoa espirra e ele já acha que é uma epidemia.

Às vezes ele acerta... às vezes exagera um pouquinho.

Recall (Sensibilidade)

Agora a pergunta muda. O recall quer saber:

"De todos os casos que realmente existiam, quantos o modelo conseguiu encontrar?"

Voltando ao banco. Imagine que existiam 200 fraudes. O sistema encontrou apenas 80. Isso significa que deixou passar 120.

Nesse caso, o recall não ficou muito bom.

Em algumas áreas, como medicina e segurança, deixar passar um caso importante pode ser muito mais grave do que gerar alguns alertas extras.

Overfitting

Agora chegamos em um dos assuntos mais famosos do Machine Learning.

O nome pode assustar, mas a ideia é simples. O overfitting acontece quando o modelo aprende demais.

"Como assim aprender demais?"

Imagine um aluno que decorou todas as questões da apostila. Ele sabe exatamente as respostas. Mas basta mudar uma palavrinha na prova que ele trava completamente.

Ele decorou. Não aprendeu. Com o modelo acontece exatamente isso. Ele fica excelente nos dados de treinamento. Mas, quando aparecem dados novos, começa a errar bastante.

É como alguém que sabe todas as perguntas do simulado, mas não consegue responder nenhuma questão diferente.

Underfitting

O underfitting é justamente o contrário. Aqui o modelo aprende de menos. É aquele aluno que abriu o livro cinco minutos antes da prova e pensou:

"Vai dar certo."

Não deu. O modelo é simples demais. Ele não consegue identificar os padrões necessários e acaba errando até situações fáceis.

Ajustando um modelo

Criar um bom modelo dificilmente acontece na primeira tentativa. Na prática, é comum fazer vários ajustes. Às vezes é preciso melhorar os dados. Em outras situações, trocar o algoritmo.

Também pode ser necessário ajustar configurações, remover informações desnecessárias ou incluir novos exemplos. O objetivo sempre é encontrar um equilíbrio. Nem decorar tudo. Nem aprender de menos.

PREPARANDO OS DADOS

Existe uma frase muito famosa entre profissionais de dados:

"Dados ruins geram resultados ruins."

Ela parece simples, mas resume boa parte do Machine Learning. Muita gente imagina que a parte mais difícil é escolher um algoritmo cheio de nomes complicados.

Na prática, muitas vezes o maior trabalho acontece antes mesmo do modelo começar a aprender. Sim... antes.

Se os dados estiverem errados, incompletos ou bagunçados, não existe algoritmo milagroso que resolva isso. É como tentar fazer um bolo usando ingredientes estragados.

Você pode ser o melhor confeitoiro do mundo, mas o resultado dificilmente será bom. Lembre-se: bagunça gera bagunça.

A importância da preparação dos dados

Os modelos aprendem analisando informações. Quanto melhor forem essas informações, maiores são as chances de o aprendizado funcionar corretamente.

Imagine ensinar uma criança a reconhecer frutas usando imagens borradas. Em uma foto a maçã está cortada. Na outra, metade da banana não aparece. Na terceira, alguém escreveu "laranja" em cima de uma foto de maçã. Confuso, não é? Se para escrever isso já foi confuso, imagine para alguém que está aprendendo.

Com a Inteligência Artificial acontece exatamente a mesma coisa. Se os exemplos forem ruins, o aprendizado também será.

Coleta de dados

O primeiro passo é conseguir os dados. Eles podem vir de praticamente qualquer lugar.

- Uma empresa pode utilizar informações armazenadas em seus sistemas.
- Um aplicativo pode registrar como os usuários utilizam determinada funcionalidade.
- Sensores podem enviar dados em tempo real.
- Hospitais armazenam exames.
- Bancos registram movimentações.

Até aquela curtida que você deu em uma rede social vira dado em algum lugar. Vivemos cercados por eles.

Limpeza dos dados

Depois da coleta vem uma das etapas mais importantes: a limpeza.

Porque dados do mundo real costumam dar trabalho. Imagine encontrar um cadastro assim:

- Nome: João
- Idade: 350 anos

Alguma coisa provavelmente deu errado. Ou então:

- Telefone vazio.
- E-mail repetido.

- CPF duplicado.
- Cidade escrita de três formas diferentes.

Tudo isso precisa ser corrigido antes do treinamento. Caso contrário, o modelo aprenderá informações erradas.

E, convenhamos, ninguém vive 350 anos... pelo menos até o momento em que escrevi esta apostila.

Dados estruturados e não estruturados

Os dados também aparecem em formatos diferentes. Os estruturados são aqueles organizados em tabelas, planilhas, bancos de dados, registros de vendas, etc. Tudo bem organizado em linhas e colunas.

Já os dados não estruturados são bem diferentes. Entram nessa categoria imagens, vídeos, áudios, documentos e textos.

São justamente esses tipos de informação que mais crescem atualmente. E também costumam dar mais trabalho para analisar.

Transformação dos dados

Nem sempre os dados chegam prontos para serem utilizados. Às vezes é necessário transformar informações. Padronizar formatos, converter textos em números, corrigir diferenças de escrita ou organizar valores. É como organizar uma mudança.

Você não joga tudo dentro da casa nova de qualquer jeito. Primeiro organiza. Depois guarda cada coisa no lugar certo.

Com os dados acontece exatamente isso.

Features

Já vimos esse nome anteriormente, mas vale reforçar. As features são as características utilizadas pelo modelo durante o aprendizado.

Imagine que queremos prever o preço de uma casa. Podemos utilizar informações como: tamanho, localização, quantidade de quartos ou idade do imóvel.

Essas características ajudam o algoritmo a entender quais fatores realmente influenciam no preço.

Escolher boas features faz bastante diferença no resultado.

Divisão dos dados

Antes do treinamento, normalmente os dados são separados em grupos.

Um grupo serve para ensinar. Outro para validar os ajustes. E outro para testar se o aprendizado realmente funcionou.

Essa separação evita que o modelo "decore" todas as respostas e cria uma avaliação muito mais confiável.

E existe um ditado que costuma fazer bastante sentido nessa área:

"Se entrar lixo, vai sair lixo."

Pode parecer engraçado, mas é exatamente isso. Não consigo pensar em algo melhor para concluir esse trecho, então vou deixar em negrito a frase acima.

AGRADECIMENTO

Se você chegou até aqui, quero te dizer: obrigada.

De verdade.

Finalizar um material assim não é só sobre aprender conteúdo. É sobre dedicação, tempo e vontade de evoluir. E só de você estar aqui, já mostra muito sobre você.

Essa apostila foi criada com um propósito muito claro: mostrar que conhecimento não precisa ser complicado. Que assuntos que parecem difíceis podem, sim, ser entendidos quando explicados da forma certa.

E mais do que isso: que conhecimento deve ser para todos.

Por isso, este material também foi pensado para ser acessível. Ele conta com versão em Braille, porque inclusão não é um diferencial — é o mínimo.

Todo mundo merece aprender. Todo mundo merece ter acesso.

Se, de alguma forma, esse conteúdo te ajudou a entender melhor, a se organizar ou até a enxergar as coisas de um jeito diferente, então ele já cumpriu o seu papel.

Obrigada por fazer parte disso.

E lembre-se: você não precisa complicar para fazer dar certo.

CONTATO

Se você quiser continuar aprendendo, trocar ideias ou acompanhar mais conteúdos sobre projetos, tecnologia e organização no dia a dia, você pode me encontrar por aqui:

Instagram: @CAROL_G_INTECH

LinkedIn: Caroline Gonçalves

Site: <https://cpgconsulting.com.br/>

E-mail: cpgtechconsulting@gmail.com

Fique à vontade para se conectar ou mandar uma mensagem. Vou adorar continuar essa troca com você.